

Entscheidungsbaum mit Fischdaten erstellen

Entscheidungsbäume · Sicherungsblatt zu Aufgabe 3a · Informatik 11

1. Fehlklassifikation und Informationsgewinn

Definition: Fehlklassifikation und Informationsgewinn


Ein Knoten sagt für seine Teilmenge das häufigere Label voraus. Alle Daten mit dem anderen Label sind **Fehlklassifikationen**. Der **Informationsgewinn** eines Splits ist

$$IG = \text{Fehler vor dem Aufteilen} - \text{Gesamtfehler nach dem Aufteilen.}$$

Gewählt wird das Attribut mit dem größten Informationsgewinn.

Beispiel: erster Split der 9 Trainingsfische

Ohne Split: alle 9 Trainingsfische




Schuppenfarbe?


Blau

Orange

Teilmenge Blau: 5 Fische



Teilmenge Orange: 4 Fische



Gesamtfehler nach dem Aufteilen: $2 + 1 = 3$

Informationsgewinn: $4 - 3 = 1$

Körper = Schuppenfarbe, Punkte = Muster, unterer Streifen = Bauchfarbe, Flossen = Flossenfarbe. Rot gestrichelt mit „Fehler“: Das Label des Fisches passt nicht zur Vorhersage seiner Gruppe.


Schuppenfarbe	friedlich	feindselig	Fehler
Fehler vor dem Aufteilen			4
Blau	3	2	2
Orange	1	3	1
Gesamtfehler nach dem Aufteilen			3
Informationsgewinn: $4 - 3 = 1$			

Attribut	Fehler nachher	IG
Schuppenfarbe	3	1
Muster	4	0
Bauchfarbe	4	0
Flossenfarbe	4	0
<i>Schuppenfarbe</i> wird die Wurzel.		

2. Wie entsteht ein Entscheidungsbaum?

Für jede entstandene **Teilmenge** wird erneut der Informationsgewinn aller Attribute bestimmt:

- **Blau** (5 Fische, 2 Fehler): *Muster* und *Bauchfarbe* haben beide IG 1. Bei diesem **Gleichstand** sind beide gleich gut geeignet; im Beispiel wird *Muster* gewählt.
- **Blau, Ohne** (2 Fische): beide friedlich, also ein **Blatt**.
- **Blau, Punkte** (3 Fische, 1 Fehler) und **Orange** (4 Fische, 1 Fehler): *Bauchfarbe* hat jeweils IG 1 und trennt fehlerfrei.



Algorithmus zum Erstellen eines Entscheidungsbaums

1. Für die aktuelle Datenmenge den Informationsgewinn jedes Attributs bestimmen.
2. Das Attribut mit dem größten Informationsgewinn wird zum **Entscheidungsknoten**.
3. Die Daten nach den Attributwerten in Teilmengen aufteilen.
4. Haben alle Daten einer Teilmenge dasselbe Label oder ist keine sinnvolle Aufteilung mehr möglich, entsteht ein Blatt mit dem häufigeren Label. Sonst das Verfahren für diese Teilmenge wiederholen.

Merke

Ein Entscheidungsbaum entsteht schrittweise. In jedem Knoten wird ein möglichst geeignetes Attribut ausgewählt. Anschließend wird das Verfahren für die entstandenen Teilmengen wiederholt.