


Klassifikation der Testdaten

Entscheidungsbäume · Sicherungsblatt zu Aufgabe 3c · Informatik 11

1. Testdaten klassifizieren

Testdaten wurden nicht zum Erstellen des Baums verwendet. Ihr tatsächliches Label ist bekannt.



Blatt = **Vorhersage**, darunter die dort ankommenden Testfische mit **tatsächlichem Label**. Körper = Schuppenfarbe, Punkte = Muster, Streifen = Bauchfarbe, Flossen = Flossenfarbe.

2. Konfusionsmatrix

erwartet \ berechnet	friedlich	feindselig	Summe
friedlich	3 richtig positiv T1, T3, T5	0 falsch negativ –	3
feindselig	1 falsch positiv T4	1 richtig negativ T2	2
Summe	4	1	5

Zeile: erwartetes, also tatsächliches Label

Spalte: berechnetes Label, also die Vorhersage

positiv = friedlich

negativ = feindselig

■ Diagonale: richtig klassifiziert

3. Genauigkeit

Definition: Genauigkeit

Die **Genauigkeit** ist der Anteil richtig klassifizierter Testdaten an allen Testdaten.

$$\text{Genauigkeit} = \frac{\text{richtig positiv} + \text{richtig negativ}}{\text{richtig positiv} + \text{falsch negativ} + \text{falsch positiv} + \text{richtig negativ}}$$

$$\begin{matrix} \text{T1} \checkmark & \text{T2} \checkmark & \text{T3} \checkmark & \text{T5} \checkmark & \text{T4} \times \end{matrix} \Rightarrow \frac{3 + 1}{3 + 0 + 1 + 1} = \frac{4}{5} = 80\%$$

Merke

Die Qualität eines Entscheidungsbaums wird mit Testdaten geprüft, nicht mit den Trainingsdaten. Die Genauigkeit beschreibt nur die verwendeten Testdaten. Sie ist keine Garantie für alle künftigen Daten.