

Künstliche Intelligenz – Einfluss von Daten auf Entscheidungsbäume

AB

Datum: _____

Beim letzten Mal hast du einen Entscheidungsbaum aus bereits beschrifteten Daten, sogenannten Trainingsdaten erstellt. Mit dessen Hilfe können neue Daten klassifiziert werden (Affen beißen oder beißen nicht bzw. Lebensmittel sind empfehlenswert oder nicht empfehlenswert).

Was passiert mit dem Entscheidungsbaum, wenn nur ganz wenige Trainingsdaten vorliegen?

1. Ganz wenige Trainingsdaten

Klicke dich durch den Auto-Entscheidungsbaum bis zur Ansicht im folgenden Bild und beschrifte in folgender Ansicht nur **die ersten 5 Lebensmittel**.

Contents

- 1 Daten und Entscheidungsbäume - So macht das ein Com...
- 2 **Daten importieren**
- 3 Daten labeln
- 4 Daten sortieren
- 5 Eine Entscheidungsregel aufstellen
- 6 Entscheidungsbaum automatisch erstellen lassen
- 7 Testdaten

Apfel	☐ eher empfehlenswert	☐ eher nicht empfehlenswert	☐ beiseite legen
Banane	☐ eher empfehlenswert	☐ eher nicht empfehlenswert	☐ beiseite legen
Haselnusschnecke	☐ eher empfehlenswert	☐ eher nicht empfehlenswert	☐ beiseite legen
Chips	☐ eher empfehlenswert	☐ eher nicht empfehlenswert	☐ beiseite legen
Pommes	☐ eher empfehlenswert	☐ eher nicht empfehlenswert	☐ beiseite legen
Nudeln	☐ eher empfehlenswert	☐ eher nicht empfehlenswert	☐ beiseite legen
Erbsen	☐ eher empfehlenswert	☐ eher nicht empfehlenswert	☐ beiseite legen
Eisbergsalat	☐ eher empfehlenswert	☐ eher nicht empfehlenswert	☐ beiseite legen

Dadurch sind nur diese als Trainingsdaten gelabelt. (Die ersten 3 Pfeile beinhalten keine Aktion, müssen aber trotzdem **alle** angeklickt werden).

Klicke anschließend unten auf den letzten Pfeil dieses Abschnitts und bestätigte die gewählten Trainingsdaten mit dem Button „Label eintragen“. Daraufhin ploppt eine Liste der Trainingsdaten auf.

Label eintragen

6 Entscheidungsbaum automatisch erstellen lassen

Eklärungstext

Jetzt übernimmt der Computer die ganze Arbeit. Das Sortieren und Auswählen der Schwellenwerte passiert ganz automatisch, indem der Computer als Möglichkeiten testet.

Aufgabe - Die Anzahl der Stufen verändern

Las automatisch einen Entscheidungsbaum erstellen. Du kannst dem Computer dabei noch sagen, wie viele Stufen der Entscheidungsbaum haben soll.

Probier mal aus, wie der Baum aussieht, wenn Du verschiedene Tiefen einstellst.


Max_Stufen: 3

Erstelle Baum

Erstelle nun im vorletzten bzw. 6. Abschnitt einen computergenerierten Entscheidungsbaum.

Anzahl korrekter Klassifikationen: 5
Anzahl Fehlklassifikationen: 0

Skizze des resultierenden computergenerierten Entscheidungsbaum:



2. Teste den Entscheidungsbaum

Überprüfe den computergenerierten Entscheidungsbaum mit weiteren Lebensmitteln

Actual \ Predicted	empfehlenswert	Nicht empfehlenswert
Empfehlenswert	Apfel, Banane, Nudeln, Erbsen, Salat, Gurke, Brokkoli, Putenbrust, Avocado, Haferflocken 10	Bratscheibe, Kartoffel, Knäckebrot, Zwieback 4
Nicht empfehlenswert	Vanilleeis, Erdbeerjoghurt, Waffel, Schokomüsli, Schokolade, Gummibärchen, Himbeermarmelade 7	Haselnussschnitte, Chips, Pommes, Frikadelle, Popcorn, Marmorkuchen, Nuggets, Mayo, Salzstangen, Räucherlachs, Spiegelei 11


Notiere stichpunktartig, wie es zu der vergleichsweise geringen Genauigkeit kommt.

Falsch gelabelt: Alles was nicht sehr salzig ist, aber trotzdem weniger empfehlenswert ist (z.B. Gummibärchen) → Anderes Merkmal oder Kombination aus mehr Merkmalen notwendig

3. Biased KI

Bearbeite nun die Auswahl an Trainingsdaten: Wähle nun alle verfügbaren Lebensmittel als Trainingsdaten aus indem du allen ein eindeutiges Label vergibst (beiseite legen ist auch ein Label, sollte aber nicht zu häufig genutzt werden).

a) Zeichne den resultierenden computergenerierten Entscheidungsbaum.



b) Überprüfe deinen Entscheidungsbaum. Nenne min. zwei Lebensmittel die trotz größerer Datenmenge ein für dich merkwürdiges Ergebnis erzielen.

Falsch (empfehlenswert): Chips, Frittierte Pommes, Chicken Nuggets, Erdbeerjoghurt, Schokomüsli, Gummibärchen, Senf

Beiseite: Frikadelle, Putenbrust, Himbeermarmelade, Salzstangen (Empfehlenswert), Salamischeibe, Schwarzwälder Schinken (nicht empfehlenswert)

- c) Beschreibe, warum es weiterhin zu merkwürdigen Ergebnissen trotz trainiertem KI-System kommen kann.

Datenmenge immer noch zu klein. Labels von Trainingsdaten sind manchmal subjektiv.

Grundannahme falsch, da es auf die Menge an Konsum ankommt.

- d) Nimm Bezug zu folgender Aussage. Beziehe deine Antwort auf die in dieser Aufgabe diskutierte Problematik von Trainingsdaten.



„2015 nahm Google seine Bilderkennungssoftware vom Markt, nachdem Menschen mit dunkler Hautfarbe als Gorillas markiert wurden.“

KI-Systeme, die mit Daten lernen, übernehmen Stereotype der Menschen, welche die Daten geliefert haben.

Dies stellt eine Grundproblematik datenbasierter KI-System dar, die kaum bis nicht behoben werden kann.