

Entscheidungsbäume

Kompaktes Lern- und Nachschlageheft · Informatik 11

1. Entscheidungsbäume

Ein **Entscheidungsbaum** ist ein Modell zur **Klassifikation**: Er ordnet neue Daten anhand ihrer Merkmale einer Klasse zu. Entscheidungsbäume können durch **überwachtes Lernen** aus Beispielen mit bekanntem Ergebnis erzeugt werden. Sie werden immer von unten nach oben durchlaufen.

Definition: Überwachtes Lernen

Beim **überwachten Lernen** wird aus **gelabelten Daten** ein Modell erzeugt. Gelabelte Daten besitzen neben ihren Merkmalen ein bekanntes **Label**, also die richtige Klasse. Das Lernverfahren sucht Regeln, mit denen es anschließend neue Eingaben klassifizieren kann.





Abbildung: Stefan Seegerer, Tilman Michaeli und Sven Jatzlau, CC BY; übernommen aus dem Ausgangsmaterial.

2. Aufbau eines Entscheidungsbaums



- Ein **Entscheidungsknoten** prüft ein Attribut.
- Eine **Kante** steht für eine Merkmalsausprägung und führt zum nächsten Knoten.
- Ein **Blatt** enthält die vorhergesagte Klasse bzw. das Label.

Beispiel: eine Vorhersage

Ein Äffchen mit *Mundform* = *offen* und *Augenstellung* = *X* folgt im obigen Baum zweimal der passenden Kante. Es erreicht das Blatt *beißt*; dies ist die Vorhersage des Modells.

3. Trainings- und Testdaten

Die verfügbaren gelabelten Daten werden getrennt verwendet:

- **Trainingsdaten** sind gelabelt bzw. beschriftet und werden zur Erzeugung des Modells verwendet.
- **Testdaten** sind gelabelt bzw. beschriftet und werden zur Beurteilung der Vorhersagequalität verwendet.

Beispiel: gelabelte Trainingsdaten

Die bekannten Äffchen sind mit den Labels *beißt* oder *beißt nicht* versehen. Aus diesen Beispielen kann ein Entscheidungsbaum Regeln für die Klassifikation neuer Äffchen lernen.

TRAININGSDATEN


Bekannte Äffchen

Vergleiche die Bilder jederzeit mit deinen Regeln.

● Beißt · 4



● Beißt nicht · 8



Beispielgrafik: vom Nutzer bereitgestellt; Äffchen-Illustrationen im Ausgangsmaterial von Annabel Lindner und Stefan Seegerer, CC BY-NC.

Merke

Die Trennung verhindert, dass ein Modell nur an bereits bekannten Daten gut wirkt. Erst neue Testdaten zeigen, wie zuverlässig seine **Vorhersagen** sind.

Zwei Entscheidungsbäume können dieselben Trainingsdaten vollständig richtig klassifizieren und bei unbekannten Testdaten trotzdem unterschiedlich gut funktionieren.

Die Trainingsdaten müssen nicht jede mögliche Merkmalskombination enthalten.

4. Wie entsteht ein Entscheidungsbaum?

1. Ein mögliches Attribut teilt die Trainingsdaten in **Teilmengen** auf. Diese Aufteilung heißt **Split**.
2. Ein **Splitkriterium** bewertet, wie eindeutig die Klassen in den Teilmengen sind.
3. Bevorzugt wird das Attribut mit dem größten **Informationsgewinn**.
4. Das Verfahren wird für die entstandenen Teilmengen wiederholt.
5. Ist keine sinnvolle weitere Aufteilung möglich oder gilt eine Abbruchbedingung, entsteht ein Blatt.

Merke

Ein gutes Attribut teilt die Daten so, dass die entstehenden Gruppen möglichst eindeutig einer Klasse zugeordnet werden können. Der Aufbau ist heuristisch: Ein optimaler Baum ist nicht garantiert.

5. Fehlklassifikation und Informationsgewinn

Eine Gruppe wird meist der Klasse zugeordnet, die darin am häufigsten vorkommt. Alle Daten der anderen Klasse wären dann **Fehlklassifikationen**. Die **Fehlklassifikationsrate** ist deren Anteil an der Gruppe.

Definition

Für eine Datenmenge X mit Klassenanteilen $p_1, \dots, p_k$ gilt

$$F(X) = 1 - \max\{p_1, \dots, p_k\}.$$

Je kleiner $F(X)$ ist, desto eindeutiger ist die Gruppe.

Nach einem Split werden die Fehler der Teilmengen nach ihrer Größe gewichtet. Für Teilmengen $X_1, \dots, X_m$ gilt:


$$F_{\text{nach}} = \sum_{j=1}^m \frac{|X_j|}{|X|} F(X_j), \quad IG_F = F(X) - F_{\text{nach}}.$$

Kompaktes Split-Beispiel

Vor dem Split enthält die Menge 10 grüne und 10 rote Objekte. Bei der Wahl einer Mehrheitsklasse entstehen 10 Fehler. Zwei Attribute liefern unterschiedliche Aufteilungen:

Attribut	Fehler vorher	Fehler nachher	Informationsgewinn
Streifen	10	$0 + 6 = 6$	$10 - 6 = 4$ Fehler
Form	10	$3 + 5 = 8$	$10 - 8 = 2$ Fehler

Das Attribut *Streifen* ist hier das "wichtigste" bzw. "beste" Attribut, weil es den größeren Informationsgewinn liefert.



Merke

Je stärker ein Split die Zahl bzw. Rate der Fehlklassifikationen verringert, desto größer ist sein Informationsgewinn. Informationsgewinn bewertet einen *Split*; er ist nicht dasselbe wie die später gemessene Genauigkeit des gesamten Modells.

6. Weitere Splitkriterien

In der Praxis werden häufig empfindlichere Maße als die Fehlklassifikationsrate verwendet. Sie messen, wie stark die Klassen in einer Datenmenge gemischt sind.

Entropie

Definition: Entropie

Für eine Menge X mit k Klassen und Klassenanteilen p_i gilt

$$E(X) = - \sum_{i=1}^k p_i \log_2(p_i).$$

Dabei werden Terme mit $p_i = 0$ als 0 gewertet. Kleine Entropie bedeutet eine relativ eindeutige Gruppe; große Entropie bedeutet eine starke Durchmischung.

Gini-Impurity

Definition: Gini-Impurity

Für dieselbe Menge gilt


$$G(X) = 1 - \sum_{i=1}^k p_i^2.$$

Auch hier zeigt ein kleiner Wert eine geringe Durchmischung. Bei einer reinen Gruppe ist $G(X) = 0$.

Für beide Kriterien wird der Wert nach einem Split nach der Größe der Teilmengen gewichtet. Allgemein, mit einem Unreinheitsmaß U :

$$IG_U(X, A) = U(X) - \sum_{j=1}^m \frac{|X_j|}{|X|} U(X_j).$$


Das Attribut A mit großem Informationsgewinn erzeugt vergleichsweise reine Teilmengen.



geringe Unreinheit



hohe Unreinheit



geringe Unreinheit

Zwei Klassen


Bei einer vollständig gemischten Menge mit $p_1 = p_2 = 0,5$ gilt $E(X) = 1$ und $G(X) = 0,5$. Besteht die Menge nur aus einer Klasse, sind beide Werte 0. Die Zahlenwerte der Kriterien sind verschieden; ihre Rolle ist jedoch ähnlich: Sie bewerten die Reinheit möglicher Splits.

Merke

Fehlklassifikationsrate, **Entropie** und **Gini-Impurity** sind verschiedene Splitkriterien. Sie dürfen nicht gleichgesetzt werden und können unterschiedliche Bäume begünstigen.

7. Testen eines Entscheidungsbaums

Nach dem Training klassifiziert der Baum die zuvor zurückgehaltenen Testdaten. Für jeden Testdatensatz werden das **vorhergesagte Label** und das **tatsächliche Label** verglichen. So lässt sich die **Vorhersagequalität** auf unbekannten Daten beurteilen.



8. Konfusionsmatrix

Eine **Konfusionsmatrix** zählt richtige und falsche Klassifikationen. Bei zwei Klassen wird eine Klasse als *positiv* festgelegt. Im Beispiel ist *feindselig* die positive Klasse.

tatsächlich \ vorhergesagt	feindselig	friedlich
feindselig	1 richtig positiv	1 falsch negativ
friedlich	0 falsch positiv	3 richtig negativ

- **richtig positiv (RP)**: positiv vorhergesagt, tatsächlich positiv
- **richtig negativ (RN)**: negativ vorhergesagt, tatsächlich negativ
- **falsch positiv (FP)**: positiv vorhergesagt, tatsächlich negativ
- **falsch negativ (FN)**: negativ vorhergesagt, tatsächlich positiv

Definition: Genauigkeit

$$\text{Genauigkeit} = \frac{\text{Anzahl korrekt klassifizierter Daten}}{\text{Anzahl aller Testdaten}} = \frac{RP + RN}{RP + RN + FP + FN}$$

Im Beispiel: $\frac{1+3}{1+3+0+1} = \frac{4}{5} = 80\%$.

9. Hyperparameter

Definition

Hyperparameter sind Einstellungen des Lernverfahrens. Sie werden vor dem Training festgelegt, nicht aus den Trainingsdaten gelernt, und beeinflussen Aufbau und Komplexität des Modells.

Wichtige Beispiele aus dem Ausgangsmaterial sind:

- **maximale Baumtiefe:** begrenzt die Zahl aufeinanderfolgender Entscheidungsebenen,
- **Splitabbruchbedingungen:** verhindern weitere Aufteilungen, etwa bei zu kleinen Teilmengen,
- **Aufteilung in Trainings- und Testdaten:** beeinflusst, wie viele Daten zum Lernen bzw. Prüfen verfügbar sind.


Ein sehr tiefer Baum kann die Trainingsdaten genau abbilden, muss aber bei neuen Daten nicht besser sein. Geeignete Einstellungen werden vor dem Training festgelegt; die endgültige Qualität wird mit Testdaten geprüft.

Merke

Trainingsdaten, Splitkriterium und Hyperparameter beeinflussen den entstehenden Baum. Sinnvolle Muster können nur gelernt werden, wenn in den Daten passende Zusammenhänge vorhanden sind.

10. Entscheidungsbäume mit Orange

Orange ist eine Data-Mining- und Machine-Learning-Software. Sie kann Entscheidungsbäume automatisch aus Daten erzeugen, Testdaten klassifizieren und Ergebnisse visualisieren. Hyperparameter lassen sich verändern; ihre Wirkung kann am Baum und an der Konfusionsmatrix untersucht werden.



Typische Orange-Widgets


File / Data Table	Daten laden und tabellarisch ansehen
Data Sampler	gelabelte Daten in Trainings- und Testdaten aufteilen
Tree / Tree Viewer	Baum erzeugen und grafisch darstellen
Predictions	Modell auf Testdaten anwenden
Confusion Matrix	vorhergesagte und tatsächliche Label auswerten

Das Wichtigste zu Entscheidungsbäumen

Merkkasten

- Ein **Entscheidungsbaum** ist ein Modell zur **Klassifikation** von Daten.
- Beim **überwachten Lernen** entsteht das Modell aus **gelabelten Trainingsdaten**.
- An jedem **Knoten** werden Daten anhand eines **Attributs** aufgeteilt; ein **Blatt** enthält eine Klasse.
- Ein **Splitkriterium** bewertet die Qualität einer möglichen Aufteilung.
- Ein möglichst großer **Informationsgewinn** ist erwünscht.
- **Fehlklassifikationsrate**, **Entropie** und **Gini-Impurity** sind mögliche Splitkriterien.
- Unabhängige **Testdaten** dienen zur Beurteilung der **Vorhersagequalität**.
- Eine **Konfusionsmatrix** zeigt richtige und falsche Klassifikationen; daraus lässt sich unter anderem die **Genauigkeit** berechnen.
- **Hyperparameter** beeinflussen Aufbau und Komplexität des Baums.
- Orange kann Training, Vorhersage und Auswertung für größere Datensätze unterstützen.

Begriffe im Zusammenhang



Grenzen des Verfahrens

Der Entscheidungsbaum-Algorithmus arbeitet heuristisch. Er findet nicht garantiert den besten Baum und kann nur Zusammenhänge nutzen, die in den Daten enthalten sind. Eine gute Bewertung auf unabhängigen Testdaten ist deshalb unverzichtbar.

Grundlage: Dr. Wolfgang Pfeffer und Tobias Fuchs, *KI@Informatik11 – Arbeitsheft*, Kapitel 1 "Entscheidungsbäume", Seiten 4–18 (Stand des vorliegenden Materials: 2023). Inhaltlich neu strukturiert und stark gekürzt. Die Diagramme dieser Schülerversion wurden in LaTeX/TikZ neu erstellt.

Im Ausgangsmaterial genannte weiterführende Quellen: AI Unplugged (<https://www.aiunplugged.org>) sowie "Von Daten und Bäumen" (<https://computingeducation.de/proj-it2school/>).