

Trainings- und Testdaten

Entscheidungsbäume · Sicherungsblatt zu Aufgabe 2.1 · Informatik 11

1. Trainings- und Testdaten

Die verfügbaren gelabelten Daten werden getrennt verwendet:

- **Trainingsdaten** sind gelabelt bzw. beschriftet und werden zur Erzeugung des Modells verwendet.
- **Testdaten** sind gelabelt bzw. beschriftet und werden zur Beurteilung der Vorhersagequalität verwendet.

Beispiel: gelabelte Trainingsdaten

Die bekannten Äffchen sind mit den Labels *beißt* oder *beißt nicht* versehen. Aus diesen Beispielen kann ein Entscheidungsbaum Regeln für die Klassifikation neuer Äffchen lernen.

TRAININGSDATEN


Bekannte Äffchen

Vergleiche die Bilder jederzeit mit deinen Regeln.

● Beißt · 4



● Beißt nicht · 8



Beispielgrafik: Äffchen-Illustrationen im Ausgangsmaterial von Annabel Lindner und Stefan Seegerer, CC BY-NC.

Merke

Die Trennung verhindert, dass ein Modell nur an bereits bekannten Daten gut wirkt. Erst neue Testdaten zeigen, wie zuverlässig seine **Vorhersagen** sind.


Zwei Bäume im Vergleich

Entscheidungsbäume · Sicherungsblatt zu Aufgabe 2.2 · Informatik 11


2. Gleiche Trainingsdaten, verschiedene Vorhersagen

Beide Bäume ordnen alle 12 Trainingsäffchen richtig ein. Sie prüfen dieselben Merkmale, aber in anderer Reihenfolge. Die Kanten sind mit der Antwort auf die jeweilige Frage beschriftet.

Baum A: zuerst X-Augen



Baum B: zuerst sichtbare Zähne



Beispiel: Äffchen 03

Äffchen 03 hat **X-Augen** und **sichtbare Zähne**. Diese Kombination kam in den Trainingsdaten nicht vor. Baum A erreicht über *X-Augen: Ja* das Blatt *beißt*. Baum B erreicht über *Zähne sichtbar: Ja* das Blatt *beißt nicht*. Das richtige Label ist *beißt*. Sobald ein Blatt erreicht ist, wird das andere Merkmal nicht mehr geprüft.

	Baum A	Baum B
Trainingsdaten	12 von 12 richtig	12 von 12 richtig
Testdaten	8 von 8 richtig	7 von 8 richtig

Merke

Zwei Entscheidungsbäume können dieselben Trainingsdaten vollständig richtig klassifizieren und bei unbekannten Testdaten trotzdem unterschiedlich gut funktionieren.
Die Trainingsdaten müssen nicht jede mögliche Merkmalskombination enthalten.